

REVIEW JURNAL 1

Judul	A Fine-Tuned Vision Transformer Based Enhanced Multi-Class Brain Tumor Classification Using MRI Scan Imagery
Jurnal	Frontiers in Oncology (Frontiers Media SA)
Volume & Halaman	Vol. 14, Article 1400341, 14 halaman
Tahun	2024
Penulis	C Kishor Kumar Reddy, Pulakurthi Anaghaa Reddy, Himaja Janapati, Basem Assiri, Mohammed Shuaib, Shadab Alam, Abdullah Sheneamer
Reviewer	M. Hibban Ramadhan
Tanggal	7 Mei 2026
Tujuan Penelitian	Penelitian ini bertujuan mengembangkan model Fine-Tuned Vision Transformer (FTVT) yang dioptimalkan untuk klasifikasi tumor otak multiclass berbasis citra MRI. Penelitian membandingkan empat varian FTVT (b16, b32, l16, l32) dengan model deep learning konvensional berbasis CNN seperti ResNet-50, EfficientNet-B0, dan MobileNet-V2, guna membuktikan superioritas arsitektur Transformer dalam analisis citra medis.
Subjek Penelitian	Citra MRI otak dari dataset gabungan tiga sumber publik: Figshare, SARTAJ, dan Br35H, yang menghasilkan total 7.023 gambar MRI otak. Dataset dikategorikan ke dalam empat kelas: Glioma, Meningioma, Pituitary Tumor, dan No Tumor. Sebanyak 5.712 gambar digunakan untuk pelatihan dan 1.311 gambar untuk pengujian. Dataset tersedia publik di Kaggle (Brain Tumor MRI Dataset).
Metode Penelitian	1. Pengumpulan dan Persiapan Dataset: Dataset MRI otak gabungan dari tiga sumber (Figshare, SARTAJ, Br35H) dikompilasi menjadi 7.023 citra dengan empat kelas tumor. Setiap citra dikaitkan dengan label kelas yang sesuai. 2. Preprocessing dan Augmentasi Data: Seluruh citra diubah ukurannya menjadi 224x224 piksel menggunakan transforms.Compose() dari library Torchvision. Augmentasi diterapkan secara acak, meliputi: (a) Horizontal Flip dengan probabilitas 0.5, citra dibalik horizontal dengan kemungkinan 50% untuk menambah variasi orientasi; (b) Random Rotation 10°, citra diputar acak hingga 10 derajat untuk mensimulasi variasi posisi pasien; (c) Color Jitter, kecerahan, kontras, saturasi, dan hue disesuaikan untuk mensimulasikan perbedaan kondisi pencahayaan MRI; (d) Konversi ke Tensor PyTorch, citra dikonversi dari format PIL Image ke tensor; (e) Normalisasi piksel untuk mempercepat

	konvergensi pelatihan. Dataset dibagi menjadi set latih, validasi, dan uji menggunakan <code>random_split()</code>. 3. Perancangan Arsitektur Model FTVT: Model Vision Transformer (ViT) pretrained dari ImageNet21k digunakan sebagai backbone, mencakup empat varian: ViT-b16 (12 transformer block, patch 16x16, dimensi 768), ViT-b32 (12 transformer block, patch 32x32, dimensi 768), ViT-l16 (24 transformer block, patch 16x16, dimensi 1024), dan ViT-l32 (24 transformer block, patch 32x32, dimensi 1024). Citra dibagi menjadi patch-patch kecil, diubah ke sequence token linear, ditambahkan position embedding, lalu diproses melalui Multi-Head Self-Attention dan MLP dalam encoder Transformer. 4. Fine-Tuning Classifier Head (FTVT): Kepala classifier bawaan ViT digantikan dengan custom classifier head yang terdiri atas lapisan berikut secara berurutan: (a) Batch Normalization (BN), menormalisasi aktivasi setiap batch; (b) Linear Layer, mereduksi dimensi fitur dari 768/1024 ke 512; (c) ReLU Activation, $f(x) = \max(0, x)$; (d) Dropout (rate=0.5), menonaktifkan neuron acak untuk mencegah overfitting; (e) Linear Layer kedua, mereduksi dimensi dari 512 ke 256; (f) ReLU dan Dropout kedua sebagai regularisasi tambahan; (g) Linear Output Layer, memetakan ke 4 kelas tumor. 5. Pelatihan Model: Model dilatih menggunakan optimizer Adam (learning rate = $1e-4$) dan Cross Entropy Loss sebagai fungsi kerugian, dengan batch size 16 citra selama 10 epoch menggunakan GPU T4 di platform Kaggle. Bobot backbone ViT dan classifier head kustom diperbarui bersama melalui backpropagation. 6. Perbandingan dengan Model CNN: Hasil FTVT dibandingkan dengan ResNet-50 (48 conv layer + residual connections), EfficientNet-B0 (compound scaling dengan MBConv blocks), dan MobileNet-V2 (17 bottleneck blocks), ketiganya di-fine-tune dengan SGD optimizer (lr=0.001, momentum=0.7). 7. Evaluasi Model: Performa diukur menggunakan Accuracy (TP+TN / total), Precision (TP / TP+FP), Recall (TP / TP+FN), dan F1-Score (harmonic mean precision dan recall), dievaluasi secara keseluruhan dan per kelas tumor.
Hasil Penelitian	Model FTVT secara konsisten mengungguli seluruh model CNN dalam semua metrik. FTVT-l16 mencapai akurasi tertinggi sebesar 98.70%, diikuti FTVT-l32 (98.62%), FTVT-b16 (98.09%), dan FTVT-b32 (96.87%). Sebagai pembanding, ResNet-50 hanya mencapai 96.5%, EfficientNet-B0 95.1%, dan MobileNet-V2 94.9%. Analisis per kelas menunjukkan bahwa kelas Meningioma paling sulit diklasifikasikan (akurasi ResNet-50 hanya 86.67%), namun FTVT-l16 berhasil meningkatkannya menjadi 98.77%. Varian patch kecil (b16, l16) terbukti lebih unggul dibanding varian patch besar (b32, l32) karena mampu menangkap detail fitur yang lebih halus dalam citra MRI.

Kekuatan	1. Arsitektur FTVT yang Inovatif: Penggantian classifier head ViT standar dengan kombinasi Batch Normalization, Dropout, dan Linear layer kustom terbukti efektif meningkatkan akurasi hingga 98.70%, melampaui studi-studi sebelumnya. 2. Analisis Komparatif Komprehensif: Membandingkan tujuh model sekaligus (4 FTVT + 3 CNN) dengan evaluasi per kelas dan per metrik secara menyeluruh. 3. Self-Attention Menangkap Dependensi Global: Mekanisme multi-head self-attention ViT mampu memahami hubungan spasial jarak jauh dalam citra MRI yang tidak bisa ditangkap receptive field lokal CNN. 4. Open Access dan Reprodusibel: Menggunakan dataset publik di Kaggle dan library open-source (PyTorch, Torchvision), sehingga mudah direproduksi. 5. Robust terhadap Overfitting: Kombinasi augmentasi data dengan regularisasi model (Dropout 0.5, Batch Normalization) secara efektif mencegah overfitting.
Kelemahan	1. Kebutuhan Komputasi Tinggi: Model FTVT varian-L memerlukan GPU T4 dengan 15 GB VRAM dan RAM 29 GB, tidak praktis untuk lingkungan dengan sumber daya terbatas. 2. Dataset Terbatas pada Tiga Jenis Tumor: Hanya mencakup Glioma, Meningioma, dan Pituitary tumor; belum mencakup jenis tumor otak lain seperti craniopharyngioma atau metastasis. 3. Tidak Ada Uji Klinis: Validasi dilakukan secara in-silico, belum diuji dalam skenario klinis nyata dengan variasi artefak dan kualitas citra yang lebih beragam. 4. Jumlah Epoch Terbatas: Pelatihan hanya 10 epoch, mungkin belum cukup untuk konvergensi optimal terutama pada varian FTVT-b32 yang memperoleh akurasi lebih rendah (96.87%).

REVIEW JURNAL 2

Judul	Skin Cancer Segmentation and Classification Using Vision Transformer for Automatic Analysis in Dermatoscopy-Based Noninvasive Digital System
Jurnal	International Journal of Biomedical Imaging (Hindawi/Wiley)
Volume & Halaman	Vol. 2024, Article ID 3022192, 17 halaman
Tahun	2024
Penulis	Galib Muhammad Shahriar Himel, Md Masudul Islam, Kh Abdullah Al-Aff, Shams Ibne Karim, Md Kabir Uddin Sikder
Reviewer	M. Hibban Ramadhan
Tanggal	7 Mei 2026
Tujuan Penelitian	Penelitian ini bertujuan membangun sistem otomatis dua tahap untuk deteksi dan klasifikasi kanker kulit berbasis citra dermoskopi noninvasif. Tahap pertama menggunakan Segment Anything Model (SAM) untuk segmentasi area lesi pada citra. Tahap kedua menggunakan berbagai varian Vision Transformer (ViT) untuk mengklasifikasikan lesi kulit menjadi kategori benign (jinak) atau malignant (ganas). Penelitian juga membandingkan enam arsitektur ViT untuk menentukan model terbaik dalam konteks klasifikasi kanker kulit.
Subjek Penelitian	Dataset HAM10000 (Human Against Machine with 10000 training images) terdiri dari 10.015 citra lesi kulit dermoskopi beresolusi tinggi yang dianotasi oleh dermatologis ahli. Dataset dibagi menjadi dua kategori: Benign (jinak) sebanyak 6.705 citra dan Malignant (ganas) sebanyak 3.310 citra. Citra mencakup tujuh jenis lesi kulit dan tersedia publik di Kaggle (Skin Cancer MNIST: HAM10000).
Metode Penelitian	1. Pengumpulan Data: Dataset HAM10000 diunduh dari repositori publik Kaggle. Citra dermoskopi beresolusi tinggi mencakup 10.015 sampel dari tujuh kategori lesi kulit yang telah dilabeli oleh dermatologis ahli. 2. Preprocessing dan Augmentasi Data: Preprocessing mencakup dua tahap: (a) Normalisasi, nilai piksel dinormalisasi untuk menstabilkan proses pelatihan dan mengurangi sensitivitas terhadap variasi pencahayaan; (b) Augmentasi, teknik augmentasi diterapkan untuk mengatasi ketidakseimbangan kelas antara benign (6.705) dan malignant (3.310), meliputi flip horizontal/vertikal, rotasi, dan perubahan kecerahan. Augmentasi dilakukan secara online selama pelatihan.

	3. Segmentasi Lesi dengan Segment Anything Model (SAM): Anotasi manual dilakukan terlebih dahulu pada area lesi kulit yang mencurigakan sebagai prompt awal untuk SAM. SAM (Meta AI) kemudian dilatih untuk menghasilkan segmentasi otomatis yang memisahkan area lesi dari kulit sehat di sekitarnya. Evaluasi segmentasi menggunakan metrik Intersection over Union (IoU) dan Dice Coefficient. 4. Perancangan Model Klasifikasi Vision Transformer: Enam arsitektur Vision Transformer diuji untuk klasifikasi biner: (a) ViT-Google (patch-32), model ViT standar dari Google dengan ukuran patch 32x32 piksel; (b) ViT-MAE, ViT dengan pretraining Masked Autoencoder dari Facebook; (c) ViT-ResNet50, ViT yang mengintegrasikan ResNet-50 sebagai hybrid backbone; (d) ViT-VAN, Visual Attention Network yang menggabungkan attention konvolusi; (e) ViT-BEiT, BERT Pretraining of Image Transformers dari Microsoft; (f) ViT-DiT, Document Image Transformer yang diadaptasi untuk citra medis. Setiap model memanfaatkan mekanisme self-attention untuk menangkap dependensi spasial jarak jauh dalam citra dermoskopi. 5. Optimasi Hyperparameter: Eksperimen dilakukan untuk menentukan kombinasi hyperparameter terbaik. Optimizer yang diuji: Adam, Adamax, RMSProp, dan SGD. Learning rate yang dievaluasi: 0.1, 0.01, 0.001, 0.0001, 0.00002, dan 0.00001. Loss function yang dibandingkan: Cross Entropy Loss dan Hinge Loss. Kombinasi terbaik yang ditemukan adalah Adam optimizer dengan learning rate 0.00002 dan Cross Entropy Loss. 6. Pelatihan dan Evaluasi: Model terbaik (ViT-Google patch-32) dilatih menggunakan konfigurasi hyperparameter optimal. Evaluasi dilakukan pada test set yang terpisah menggunakan metrik akurasi keseluruhan dan false negative ratio. Keenam model ViT dibandingkan secara head-to-head untuk menentukan arsitektur terbaik pada tugas klasifikasi kanker kulit ini.
Hasil Penelitian	Tahap segmentasi menggunakan SAM menghasilkan Intersection over Union (IoU) sebesar 96.01% dan Dice Coefficient sebesar 98.14%, menunjukkan kualitas segmentasi lesi yang sangat akurat. Pada tahap klasifikasi, ViT-Google (patch-32) tampil sebagai model terbaik dengan akurasi 96.15% dan false negative ratio rendah pada test dataset. ViT-BEiT dan ViT-MAE menunjukkan performa kompetitif, sementara ViT-DiT memberikan hasil terendah di antara keenam model. Kombinasi pipeline segmentasi-klasifikasi dua tahap terbukti lebih efektif daripada pendekatan klasifikasi langsung tanpa segmentasi.
Kekuatan	1. Pipeline Dua Tahap yang Inovatif: Integrasi SAM untuk segmentasi dan ViT untuk klasifikasi membentuk pipeline komprehensif dan end-to-end, memungkinkan deteksi kanker kulit sepenuhnya otomatis dari citra dermoskopi.

	2. Penggunaan SAM yang Mutakhir: Segment Anything Model adalah model segmentasi universal terkini (2023) dari Meta AI. Penelitian ini menjadi salah satu yang pertama mengadopsinya untuk segmentasi lesi kulit medis. 3. Perbandingan Enam Arsitektur ViT: Evaluasi komprehensif terhadap enam varian ViT memberikan panduan berguna bagi peneliti dalam memilih arsitektur yang tepat untuk tugas klasifikasi citra medis serupa. 4. Orientasi Klinis yang Kuat: Penelitian menekankan pentingnya false negative ratio, metrik yang sangat relevan secara klinis karena kasus kanker tidak terdeteksi jauh lebih berbahaya daripada false positive. 5. Potensi Implementasi Real-Time: Sistem dirancang untuk dapat dipasang pada perangkat pintar yang terhubung dermatoskop, membuka peluang aplikasi diagnosis cepat di layanan kesehatan primer.
Kelemahan	1. Klasifikasi Biner yang Terbatas: Penelitian hanya mengklasifikasikan lesi menjadi dua kategori (benign/malignant), padahal secara klinis dibutuhkan klasifikasi lebih granular ke tujuh sub tipe lesi dalam HAM10000. 2. Ketergantungan pada Anotasi Manual untuk SAM: Tahap segmentasi SAM masih memerlukan anotasi prompt manual sebagai input awal, sehingga belum sepenuhnya otomatis dan masih bergantung pada keahlian operator. 3. Ketidakseimbangan Kelas Tidak Dibahas Mendalam: Rasio kelas benign:malignant yang tidak seimbang (6705:3310) berpotensi memengaruhi bias model, namun strategi penanganannya tidak dijelaskan secara rinci. 4. Detail Arsitektur Kurang Lengkap: Paper tidak menyertakan detail konfigurasi fine-tuning masing-masing model ViT (jumlah layer di-freeze, batch size, epoch), sehingga sulit mereproduksi hasil secara persis.

REVIEW JURNAL 3

Judul	A Hybrid Neural Network Approach for Classifying Diabetic Retinopathy Subtypes
Jurnal	Frontiers in Medicine (Frontiers Media SA)
Volume & Halaman	Vol. 10, Article 1293019, 12 halaman
Tahun	2024
Penulis	Huanqing Xu, Xian Shao, Dandan Fang, Fangliang Huang
Reviewer	M. Hibban Ramadhan
Tanggal	7 Mei 2026
Tujuan Penelitian	Penelitian ini bertujuan meningkatkan akurasi prediksi tingkat keparahan Diabetic Retinopathy (DR) melalui model hybrid neural network yang menggabungkan EfficientNet dan Swin Transformer. Model dirancang untuk mengatasi keterbatasan CNN murni yang hanya menangkap fitur lokal, dan Transformer murni yang kurang optimal untuk fitur lokal lesi. Tujuan sekunder adalah menghasilkan visualisasi Class Activation Map (CAM) yang dapat diinterpretasi dokter sebagai alat bantu diagnosis klinis.
Subjek Penelitian	Dataset APTOS 2019 Blindness Detection, dataset publik berskala besar yang tersedia di Kaggle, terdiri dari 3.662 citra fundus retina pasien diabetik. Dataset diklasifikasikan menjadi 5 tingkat keparahan DR: Grade 0 (No DR), Grade 1 (Mild DR), Grade 2 (Moderate DR), Grade 3 (Severe DR), dan Grade 4 (Proliferative DR). Citra diambil menggunakan kamera fundus standar di berbagai klinik dengan kondisi pencahayaan dan kualitas yang bervariasi.
Metode Penelitian	1. Pengumpulan Dataset: Dataset APTOS 2019 Blindness Detection diunduh dari kompetisi Kaggle. Dataset mencakup 3.662 citra fundus retina berlabel yang diperoleh dari layanan skrining DR di berbagai klinik di India. 2. Preprocessing dan Augmentasi Data: Tahap preprocessing mencakup tiga langkah: (a) Gaussian Blur, filter Gaussian diterapkan pada seluruh citra fundus untuk mengurangi noise dan menghaluskan tekstur yang tidak relevan, sekaligus membantu model mengidentifikasi pola lesi yang lebih signifikan; (b) Augmentasi Data, diterapkan teknik random flip, rotasi, dan perubahan kontras untuk meningkatkan keberagaman data latih dan mengatasi ketidakseimbangan distribusi antar grade DR; (c) Normalisasi, nilai piksel dinormalisasi ke rentang [0,1] untuk mempercepat konvergensi selama pelatihan.

	3. Perancangan Cabang EfficientNet (Local Feature Extractor): EfficientNet digunakan sebagai cabang pertama model hybrid untuk mengekstraksi fitur lokal. EfficientNet menggunakan compound scaling yang menyeimbangkan depth, width, dan resolution jaringan secara proporsional melalui serangkaian Mobile Inverted Bottleneck Convolution (MBConv) blocks yang efisien secara komputasi. EfficientNet unggul dalam menangkap detail lesi mikroskopis seperti microaneurysm, hemorrhage, dan eksudat yang bersifat lokal dalam citra fundus. 4. Perancangan Cabang Swin Transformer (Global Feature Extractor): Swin Transformer digunakan sebagai cabang kedua untuk mengekstraksi fitur global. Arsitektur Swin Transformer memperkenalkan local window attention mechanism dengan ukuran jendela tetap, dan cross-stage information exchange melalui shifted window attention, sehingga mampu menangkap dependensi jarak jauh secara efisien. Hal ini memungkinkan model memahami konteks global seperti distribusi area lesi, perubahan pola vaskular, dan hubungan spasial antar-region retina. 5. Feature Fusion (Penggabungan Fitur Hybrid): Output feature map dari EfficientNet (fitur lokal) dan Swin Transformer (fitur global) digabungkan melalui mekanisme feature fusion. Penggabungan menghasilkan representasi yang mencakup detail lokal lesi sekaligus konteks global retina, yang menjadi kunci peningkatan akurasi klasifikasi DR dibandingkan model tunggal. 6. Pelatihan Model: Model hybrid dilatih pada dataset APTOS 2019 menggunakan teknik optimasi yang telah disetel. Class Activation Map (CAM) diimplementasikan secara bersamaan untuk menghasilkan visualisasi area yang diperhatikan model saat membuat keputusan, meningkatkan interpretabilitas bagi klinisi. 7. Evaluasi dan Perbandingan: Performa model dievaluasi menggunakan empat metrik: Accuracy (keakuratan keseluruhan), Sensitivity (kemampuan mendeteksi kasus positif DR), Specificity (kemampuan mengidentifikasi non-DR), dan AUC (Area Under the ROC Curve). Hasil dibandingkan dengan model deep learning mainstream lain pada dataset yang sama.
Hasil Penelitian	Model hybrid EfficientNet + Swin Transformer mencapai performa terbaik di antara seluruh model yang dibandingkan pada dataset APTOS 2019, dengan nilai: Sensitivity 0.95, Specificity 0.98, Accuracy 0.97, dan AUC 0.97. Hasil ini secara signifikan melampaui model berbasis CNN tunggal maupun Transformer murni. Visualisasi Class Activation Map (CAM) berhasil menyorot area retina yang relevan secara klinis (area lesi DR) sebagai basis keputusan model, membuktikan model tidak hanya akurat tetapi juga dapat diinterpretasi. Penerapan Gaussian Blur dan augmentasi data meningkatkan robustness model terhadap variasi kualitas citra fundus dari berbagai klinik.

Kekuatan	1. Kombinasi Hybrid yang Komplementer: Penggabungan EfficientNet (unggul fitur lokal) dan Swin Transformer (unggul fitur global) secara konseptual kuat dan terbukti menghasilkan akurasi lebih tinggi daripada masing-masing model secara terpisah. 2. Interpretabilitas melalui CAM: Visualisasi Class Activation Map menjadikan model tidak sekadar black box, dapat menjelaskan area mana yang menjadi dasar keputusan, sangat penting untuk kepercayaan klinisi dalam adopsi AI medis. 3. Performa Metrik yang Seimbang: Nilai AUC 0.97 dan Specificity 0.98 menunjukkan model tidak hanya akurat secara keseluruhan tetapi juga memiliki tingkat false alarm rendah, penting dalam konteks skrining massal DR. 4. Dataset Real-World Berskala Besar: APTOS 2019 dikumpulkan dari kondisi klinis nyata di berbagai klinik, sehingga validasi pada dataset ini mencerminkan kemampuan generalisasi model yang lebih realistis. 5. Kontribusi pada Pencegahan Kebutaan: Deteksi dini DR yang akurat memiliki dampak klinis langsung dalam mencegah kebutaan pada pasien diabetes, menjadikan penelitian ini memiliki relevansi dan urgensi sosial tinggi.
Kelemahan	1. Ukuran Dataset yang Relatif Kecil: Dataset APTOS 2019 hanya 3.662 citra, tergolong kecil untuk melatih model hybrid yang kompleks, meningkatkan risiko overfitting meskipun sudah diterapkan augmentasi. 2. Detail Teknis Fusion Tidak Eksplisit: Paper tidak menjelaskan secara rinci mekanisme feature fusion antara EfficientNet dan Swin Transformer (concatenation, addition, atau attention-based fusion). 3. Ketidakseimbangan Distribusi Kelas: Distribusi 5 grade DR dalam APTOS 2019 sangat tidak merata (mayoritas Grade 0), namun strategi penanganan class imbalance tidak dibahas mendalam. 4. Belum Divalidasi pada Populasi Beragam: Model hanya divalidasi pada satu dataset dari satu kompetisi. Kemampuan generalisasi pada populasi pasien lebih beragam (ras, usia, alat berbeda) belum dapat dijamin.